

①  
现在我们来解释 EEG 源的无拘问题

$$\min_u \left\{ \frac{1}{2} \|Au - b\|_2^2 + \lambda TV_\alpha(u) \right\} \quad (2)$$

即

$$\min_{u,v} \left\{ \frac{1}{2} \|Au - b\|_2^2 + \lambda \|v\|_1 \right\}, \text{ subject to } D_\alpha u = v.$$

的 ADMM 算法 (3) 及另一种应用 Pock - Chambolle 算法思想去改进的加速迭代方法 (4).

$$\min_u \left\{ \frac{1}{2} \|Au - b\|_2^2 + \lambda \|D_\alpha u\|_1 \right\}$$

$$\min_{u,v} \left\{ \frac{1}{2} \|Au - b\|_2^2 + \lambda \|v\|_1 \right\}, \text{ subject to } v = D_\alpha u$$

用 ADMM 方法: (Alternating direction method of multipliers) 即约束条件为  $D_\alpha u - v = 0$

用 Lagrange 乘数法, 将目标函数更改为

$$\min_{u,v} \left\{ \frac{1}{2} \|Au - b\|_2^2 + \lambda \|v\|_1 + \rho \langle \tilde{v}, D_\alpha u - v \rangle + \frac{\rho}{2} \|D_\alpha u - v\|_2^2 \right\}$$

Lagrange 乘子

↑ 添上这一项

交替迭代

对  $v$  而言:

$$\min_v \left\{ \lambda \|v\|_1 + \rho \langle \tilde{v}, v \rangle + \frac{\rho}{2} \|D_\alpha u - v\|_2^2 \right\}$$

$$\Leftrightarrow \min_v \left\{ \lambda \|v\|_1 + \frac{\rho}{2} \|v - (D_\alpha u + \tilde{v})\|_2^2 - \frac{\rho}{2} \|\tilde{v}\|_2^2 \right\}$$

$$\Leftrightarrow \min_v \left\{ \|v\|_1 + \frac{1}{2 \cdot \frac{\rho}{\lambda}} \|v - (D_\alpha u + \tilde{v})\|_2^2 \right\}$$

$$\Leftrightarrow v = \text{Prox}_{\frac{\lambda}{\rho}}^{\|\cdot\|_1} (D_\alpha u + \tilde{v})$$

$$\Leftrightarrow v = \text{Shrink}(D_\alpha u + \tilde{v}), \text{ 这里 } \text{Shrink}(u, \mu)_i = \text{Sign}(u_i) \max\{|u_i| - \mu, 0\}.$$

对  $u$  而言:

$$\min_u \left\{ \frac{1}{2} \|Au - b\|_2^2 + \rho \langle \tilde{v}, D_\alpha u \rangle + \frac{\rho}{2} \|D_\alpha u - v\|_2^2 \right\}$$

$$\Leftrightarrow \min_u \left\{ \frac{1}{2} \|Au - b\|_2^2 + \rho \langle D_\alpha^T \tilde{v}, u \rangle + \frac{\rho}{2} \|D_\alpha u - v\|_2^2 \right\}$$

$$\Leftrightarrow \min_u \left\{ \frac{1}{2} \|Au - b\|_2^2 + \frac{\rho}{2} \|D_\alpha u - (v - \tilde{v})\|_2^2 \right\}$$

∴ 对  $u$  求导, 得到

$$A^T (Au - b) + \rho D_\alpha^T (D_\alpha u - (v - \tilde{v})) = 0$$

$$\therefore (A^T A + \rho D_\alpha^T D_\alpha) u = A^T b + \rho D_\alpha^T (v - \tilde{v})$$

$$\therefore u = (A^T A + \rho D_\alpha^T D_\alpha)^{-1} (A^T b + \rho D_\alpha^T (v - \tilde{v}))$$

对  $\tilde{v}$  而言, 对  $\tilde{v}$  求导, 令其等于 0 得到  $\rho (D_\alpha u - v)$

$$\therefore \tilde{v} \leftarrow v + \gamma (D_\alpha u - v), \text{ 取 } \gamma \in (0, \frac{\sqrt{5}+1}{2}).$$

讨论  $G(x) + \frac{1}{2\tau} \|x - \hat{x}\|_2^2$  的极小化问题,

定义:  $\text{Prox}_{\frac{G}{\tau}}(\hat{x}) = \arg \min_x G(x) + \frac{1}{2\tau} \|x - \hat{x}\|_2^2$

$$0 \in \partial G(x) + \frac{1}{\tau} (x - \hat{x})$$

$$\therefore 0 = \tau \partial G(x^*) + (x^* - \hat{x})$$

$$\therefore x^* + \tau \partial G(x^*) = \hat{x}$$

$$\therefore (1 + \tau \partial G)^{\#}(x^*) = \hat{x},$$

$$\text{即 } x^* = (1 + \tau \partial G)^{-1} \hat{x}$$

$$\text{也即 } x^* \text{ 为 } x^* = \text{Prox}_{\frac{G}{\tau}}(\hat{x})$$

预备讨论

$$\min_x F(Kx) + G(x)$$

$\longleftrightarrow$

利用 Fenchel 对偶函数的概念:

$$\text{令 } F^*(t) = \max_x \{ \langle t, x \rangle - F(x) \}$$

$$\text{显然有 } (F^*)^* = F.$$

$$\therefore F(y) = \max_t \{ \langle y, t \rangle - F^*(t) \}$$

$\therefore$  问题重述

$$\min_x \left\{ \max_y \left( \langle Kx, y \rangle - F^*(y) \right) + G(x) \right\}$$

所以除了原问题的变量  $x$  外, 增加了辅助变量  $y$ .  
(的对偶)



迭代了  $k$  步, 已得到  $x^k, y^k$  的值.

现在要进行  $k+1$  号迭代:

对  $x^{k+1}$ :

$$\begin{aligned} & \min_x \{ G(x) + \langle Kx, y^k \rangle \} \\ \text{再加一项:} & \quad x^{k+1} = \operatorname{argmin}_x \left\{ G(x) + \underbrace{\langle Kx, y^k \rangle}_{= \langle x, K^T y^k \rangle} + \frac{1}{2\tau} \|x - x^k\|_2^2 \right\} \\ & \quad \quad \quad \uparrow \text{因为 } x^{k+1} \text{ 在 } x^k \text{ 附近} \\ & = \operatorname{argmin}_x \left\{ G(x) + \frac{1}{2\tau} \|x - (x^k - \tau K^T y^k)\|_2^2 \right\} \\ & = \operatorname{Prox}_\tau^G (x^k - \tau K^T y^k) \\ & = (1 + \tau \partial G)^{-1} (x^k - \tau K^T y^k). \end{aligned}$$

对  $y^{k+1}$ :

$$\max_y \{ \langle Kx^{k+1}, y \rangle - F^*(y) \} \Leftrightarrow \min_y \{ F^*(y) - \langle Kx^{k+1}, y \rangle \}$$

再加一项:

$$\begin{aligned} y^{k+1} &= \operatorname{argmin}_y \left\{ F^*(y) - \langle y, Kx^{k+1} \rangle + \frac{1}{2\sigma} \|y - y^k\|_2^2 \right\} \\ &= \operatorname{argmin}_y \left\{ F^*(y) + \frac{1}{2\sigma} \|y - (y^k + \sigma Kx^{k+1})\|_2^2 \right\} \\ &= \operatorname{Prox}_\sigma^{F^*} (y^k + \sigma Kx^{k+1}) \\ &= (1 + \sigma \partial F^*)^{-1} (y^k + \sigma Kx^{k+1}) \end{aligned}$$

可以再用  $x^{k+1} + \theta(x^{k+1} - x^k)$  来替代

当  $\theta=1$  时, 为  $2x^{k+1} - x^k$ .

于是

$$\begin{aligned} x^{k+1} &= (1 + \tau \partial G)^{-1} (x^k - \tau K^T y^k) \\ y^{k+1} &= (1 + \sigma \partial F^*)^{-1} (y^k + \sigma K(x^{k+1} + \theta(x^{k+1} - x^k))) \end{aligned}$$

$\tau, \sigma$  分别为  $x^k, y^k$  的迭代步长. 但对向量  $x^k$  的迭代步长  $(x^k)$  而言, 迭代步长是一致的.

$$\langle x_1, x_2 \rangle_X = \langle T^{-1} x_1, x_2 \rangle \quad (5)$$

$$\langle y_1, y_2 \rangle_Y = \langle \Sigma^{-1} y_1, y_2 \rangle$$

$$\begin{cases} x^{k+1} = (I + T \partial G)^{-1} (x^k - T K^T y^k) \\ y^{k+1} = (I + \Sigma \partial F^*)^{-1} (y^k + \Sigma K (x^{k+1} - \partial(x^{k+1} - x^k))) \end{cases}$$

$$\begin{aligned} x^* &= \arg \min_x G(x) + \frac{1}{2} \|x - \hat{x}\|_X^2 \\ 0 &\in \partial G(x^*) + T^{-1}(x^* - \hat{x}) \\ \therefore 0 &\in \partial G(x^*) + T^{-1}(x^* - \hat{x}) \end{aligned}$$

$$\therefore x^* = (I + T \partial G)^{-1}(\hat{x})$$

由  $G$  及  $F^*$  的凸性知:

$\forall (x, y) \in X \times Y$ , 有不等式:

$$\left\langle \begin{pmatrix} x - x^{k+1} \\ y - y^{k+1} \end{pmatrix}, F \begin{pmatrix} x^{k+1} \\ y^{k+1} \end{pmatrix} + M \begin{pmatrix} x^{k+1} - x^k \\ y^{k+1} - y^k \end{pmatrix} \right\rangle \geq 0$$

$$\text{这里 } F \begin{pmatrix} x^{k+1} \\ y^{k+1} \end{pmatrix} = \begin{pmatrix} \partial G(x^{k+1}) + K^T y^{k+1} \\ \partial F^*(y^{k+1}) - K x^{k+1} \end{pmatrix}$$

$$M = \begin{pmatrix} T^{-1} & -K^T \\ -\partial K & \Sigma^{-1} \end{pmatrix}$$

~~这里~~ proximal point algorithm 的形式 (可参考 Pock-Chambolle 2011 年文章)

对  $\theta, T, \Sigma$  加上何种条件能保证算法的收敛性?

如  $\theta=1$ ,  $T, \Sigma$  满足

$$\|\Sigma^{1/2} K T^{-1/2}\|^2 < 1$$

则可推出  $M$  为对称正定, 即

$$\forall (x, y) \in X \times Y, \text{ 有 } \begin{pmatrix} x \\ y \end{pmatrix} \neq 0, M \begin{pmatrix} x \\ y \end{pmatrix} > 0$$

迭代序列  $\begin{pmatrix} x^n \\ y^n \end{pmatrix}$  弱收敛于 最优问题 (1) 的一个最优解  $\begin{pmatrix} x^* \\ y^* \end{pmatrix}$ .

(6)

对于  $G, F^*$  的近似, 则  $T, \Sigma$  取为对称阵.

$$\text{令 } T = \text{diag}(\tau), \quad \tau = (\tau_1, \dots, \tau_n), \quad \tau_j = \frac{1}{\sum_{i=1}^m |K_{ij}|^{2-\alpha}}$$

$$\Sigma = \text{diag}(\sigma), \quad \sigma = (\sigma_1, \dots, \sigma_m)$$

$$\sigma_i = \frac{1}{\sum_{j=1}^n |K_{ij}|^\alpha}$$

上述是  
非对称阵近似

$$\|\Sigma^{1/2} K T^{1/2}\|^2 = \sup_{x \in X, x \neq 0} \frac{\|\Sigma^{1/2} K T^{1/2} x\|^2}{\|x\|^2} \leq 1$$

这里,  $\forall \alpha \in [0, 2]$

为使 " $< 1$ ",

有时  $\tau \rightarrow \mu^\tau$ , 且  $\mu^\tau < 1$ .

$\sigma \rightarrow \nu^\sigma$

$\therefore$  收敛性得以待证.

现在再回到原来的凸函数曲面上的TV问题:

$$\min_u \left\{ \frac{1}{2} \|Au - b\|_2^2 + \lambda \|D_x u\|_1 \right\}$$

令

$$F_1(\cdot) = \frac{1}{2} \|\cdot\|_2^2, \quad F_2(\cdot) = \lambda \|\cdot\|_1$$

则问题可写为

$$\min_u \max_{s, t} \left\{ \langle Au - b, t \rangle - F_1^*(t) + (\langle D_x u, s \rangle - F_2^*(s)) \right\}$$

现在来计算  $F_1^*$  及  $F_2^*$ :

(1) 对  $F_1$ , 有

$$\begin{aligned} F_1^*(t) &= \max_x \left\{ \langle t, x \rangle - F_1(x) \right\} = \max_x \left\{ \langle t, x \rangle - \frac{1}{2} \|x\|_2^2 \right\} \\ &= \max_x \left\{ -\frac{1}{2} (\|x - t\|_2^2 + \|t\|_2^2) \right\} \\ &= \min_x \frac{1}{2} (\|x - t\|_2^2 + \|t\|_2^2) \end{aligned}$$

因为当  $x=t$  时达到极小, 所以极小值为  $\frac{1}{2} \|t\|_2^2$ , 即

$$F_1^*(t) = \frac{1}{2} \|t\|_2^2$$

(2) 对  $F_2$ , 有

$$\begin{aligned} F_2^*(s) &= \max_p (\langle s, p \rangle - \lambda \|p\|_1), \quad \text{用分量形式可表为} \\ &= \lambda \max_p \left\{ \frac{1}{\lambda} \sum_i s_i p_i - \sum_i |p_i| \right\} \\ &= \lambda \sum_i \max_{p_i} \left( \frac{s_i}{\lambda} p_i - |p_i| \right) \end{aligned}$$

因为  $|\frac{s_i}{\lambda}| \leq 1$  时,  $\max_{p_i} \left( \frac{s_i}{\lambda} p_i - |p_i| \right) = 0$ , 否则为  $+\infty$ ,  
 所以

$$F_2^*(s) = \begin{cases} 0, & \|s\|_\infty \leq \lambda \\ +\infty, & \text{否则} \end{cases}$$



所以(4)式中,

关于  $x^{k+1}$  的迭代式中的  $(I + \Sigma \partial G)^{-1}$ , 由于  $G=0$ , 所以退化为  $I$ .

关于  $t^{k+1}$  的迭代式中的  $(I + \Gamma_2 \partial F_1^*)^{-1}$ , 由于  $F_1^*(t) = \frac{1}{2} \|t\|_2^2$ , 所以

$$\partial F_1^* = I, \text{ 因此退化为 } (I + \Gamma_2)^{-1}$$

而关于  $s^{k+1}$  的迭代式中的  $(I + \Gamma_1 \partial F_2^*)^{-1}(\tilde{s})$

我们换一种表达方式:

$$s^{k+1} = \text{prox}_{F_2^*}(\tilde{s})$$

$$\tilde{s} = s^k + \Gamma_1 D_s (x^k - \Sigma (D_s^T s^k + A^T x^k))$$

这里

$$= \arg \min_s \left\{ F_2^*(s) + \frac{1}{2} \|s - \tilde{s}\|^2 \right\}$$

用欧几里得范数  $\Gamma_1$  乘的系数

由于

$$F_2^*(s) = \begin{cases} 0, & \|s\|_\infty \leq \lambda \\ +\infty, & \text{否则} \end{cases}$$

所以投影操作只能在  $\|s\|_\infty \leq \lambda$  中进行, 在此区域中找到一点与  $\tilde{s}$  最接近,  
(Box 区域)

最后就得到了

$$s^{k+1} = \text{Proj}_{\|s\|_\infty \leq \lambda}(\tilde{s}),$$

即把  $\tilde{s}$  投影到 Box 区域中去, 投影点即为  $s^{k+1}$   
(投影点为  $\Gamma_1$  内被选择元素)  
(准确)