

大尺度变形的图像配准及公共模板的确定

Large deformation image registration and atlas building

华东师范大学数学系 沈纯理

本文旨在介绍 Large Deformation Diffeomorphic Metric Mapping (LDDMM) 技术及其相关内容。

§1. 微分同胚流形中的映射

弹性变形，即微分同胚，它是一个保持双方一一对应的可逆的光滑映射。

$$\begin{aligned}\phi: \Omega &\longrightarrow \phi(\Omega) \\ x &\longmapsto \phi(x)\end{aligned}$$

如果微分同胚是小变形的，则 $\phi(x) \approx x + u(x)$ ，其中 $u(x)$ 是在 x 处的向量，即它是区域 Ω 上的一个向量场。所以微小变形的微分同胚可以用 Ω 上的一个向量场来实现。

当微分同胚 $\phi(x)$ 是大变形时，如何描述？可以让它一点一点地变过去，即大变形的微分同胚可通过一个连续变形过程来实现，而变形过程可用一族依赖于时间 $t \in [0, 1]$ 的微分同胚 $\phi_t(x)$ 来描述，其中 $\begin{cases} \phi_0 = \text{id} \\ \phi_1 = \phi \end{cases}$ 。也就是说，大变形的微分同胚可以通过一族依赖于时间 t 的向量场 v_t 来实现，

其中

$$v_t(\phi_t(x)) = \frac{d\phi_t(x)}{dt}, \quad \text{且 } \phi_t|_{t=0} = \text{id}.$$

反之, 如有一族依赖于时间变化的向量场 $v_t(x)$, 则从常微分方程组

$$\begin{cases} \frac{d\phi_t(x)}{dt} = v_t(\phi_t(x)) \\ \phi_t|_{t=0} = id \end{cases} \quad (1)$$

中可以解出一族依赖于时间变化的微分同胚 $\phi_t(x)$. 因此, 一族依赖于 t 的微分同胚可等价地描述为一族依赖于 t 的向量场.

如果我们定义 V 为 Ω 上所有向量场所构成的向量空间, 则一族依赖于 t 的微分同胚就相当于在 V 空间中的一条曲线. 更严格地说, 微分同胚流形中的一条以 t 为参数的曲线的切向量场相当于 V 空间中的一条曲线.

我们可以在向量空间 V 上定义一个内积:

设 $a, b \in V$, (即 a, b 均为 Ω 上的向量场), 则令

$$\langle a, b \rangle_V = \langle La, b \rangle_{L^2} = \int_{\Omega} \langle La(x), b(x) \rangle dx, \quad (2)$$

其中 L 是一个正定的, 自共轭微分算子

$$L: V \longrightarrow V^*,$$

这里 V^* 是 V 的对偶空间. 例如, 我们可采用

$$L = -\alpha \Delta + \beta,$$

其中 Δ 是 Laplace 算子, α, β 为正常数.

设 $v \in V$ 是一个向量场, 则称

$$m = Lv \in V^* \quad (3)$$

为与 v 相对偶的动量 (momentum), 并记 L 的逆算子为 $K: V^* \longrightarrow V$.

对 V 中的每一条曲线 $v_t, t \in [0, 1]$, 可定义其能量

$$E(v_t) = \int_0^1 \langle v_t, v_t \rangle_V dt = \int_0^1 \langle L v_t, v_t \rangle_{L^2} dt \quad (4)$$

则由这个能量的 Euler-Lagrange 方程可求出该能量的极值曲线 (也称测地线)。

记这条测地线 v_t 的对偶曲线为 $m_t = L^* v_t \in V^*$, 则测地线 v_t 应满足所谓的

EPDiff 方程

$$\frac{\partial v}{\partial t} = -K(ad_v^* m) = -K((Dv)^T m + Dm v + m \operatorname{div}(v)), \quad (5)$$

(这里省略了 v_t, m_t 的下标 t), 而其中 D 为 Jacobian 矩阵, 算子 ad_v^* 是算子 $ad_v: V \rightarrow V$ 的对偶算子, 即

$$\langle u, ad_v^* m \rangle_{L^2} = \langle ad_v u, m \rangle_{L^2},$$

而

$$ad_v w = -[v, w] = Dv w - Dw v,$$

这里 $[v, w]$ 是向量场 v, w 的 Jacobi-Lie 括号, 即对函数 f , 有

$$[v, w](f) = v(w(f)) - w(v(f)).$$

注: EPDiff 方程的推导引自 Miller, M.I., Trounev, A., Younes, L., 2006, Geodesic Shooting for Computational anatomy, J. Math. Imaging, Vis. 24 (2), 209-228 中查到。

* EPDiff 方程也可写成 $\frac{\partial m}{\partial t} = -ad_v^* m$.

* 沿着测地线, 成立

$$\frac{d}{dt} (\langle v, v \rangle_V) = 0,$$

即沿测地线, $\|v\|_V^2$ 为常值。

这是因为

$$\begin{aligned}\frac{d}{dt} \|v\|_V^2 &= 2 \langle v, \frac{dv}{dt} \rangle_V = 2 \langle v, -K(\text{ad}_V^* m) \rangle_V \\ &= -2 \langle L v, K(\text{ad}_V^* m) \rangle_{L^2} = -2 \langle v, \text{ad}_V^* m \rangle_{L^2} \\ &= -2 \langle \text{ad}_V v, m \rangle_{L^2} = 0.\end{aligned}$$

* 因为 EPD 方程是一阶的 ODE, 所以由初始向量场 v_0 就可确定出整条测地线.

这就是所谓的测地射击 (geodesic shooting).

* 沿着 V 中的曲线 v_t , 用

$$\begin{cases} \frac{d\phi_t(x)}{dt} = v_t(\phi_t(x)) \\ \phi_t|_{t=0} = \text{id} \end{cases}$$

可给出一族微分同胚 ϕ_t , 由此可得出一族变换图像, 即初始图像 $I_0(x)$

随着微分同胚 ϕ_t 可得出一族变换图像

$$I_t(x) = I_0(\phi_t^{-1}(x)).$$

这族变换图像 I_t 满足图像迁移方程:

$$\frac{dI_t}{dt} + v \cdot \nabla I_t = 0. \quad (6)$$

§2. 两个图像之间的配准

现在考虑图像 I_0 和 I 的配准问题.

定义能量

$$E(v, I_0, J) = \frac{1}{2} \int_0^1 \langle L v_t, v_t \rangle_{L^2} dt + \frac{1}{2\sigma^2} \|I_0 \circ \phi_1^{-1} - J\|_{L^2}^2, \quad (7)$$

这里 $v \in L^2([0, 1], V)$, 即 $v_t \in V, t \in [0, 1]$, 是一族依赖于 t 的向量场 (相当于随着时间 t , 从 0 到 1 的一族微分同胚). 能量 E 的表达式中右边第二项表示为由 v_t 所生成的在 $t=1$ 处的微分同胚中, 所生成的变换图像 I_1 与图像 J 之间的误差, 而右边第一项是这个微分同胚族的正则项. 配准问题就相当于求去找

$$v^* = \operatorname{argmin}_{v \in L^2([0, 1], V)} E(v, I_0, J).$$

但这个问题解决起来太复杂, 因为 v_t 的变化自由度太大了, 不易处理.

所以我们运用测地射击 (geodesic shooting) 方法. 设定: 将能量 E 中的 v 限制为 V 中的测地线, 即 $v = (v_t)$ 还应满足 EPDiff 方程. 这时整条 v_t 曲线能由初始向量 v_0 所确定, 于是自由度就大为减少了. 因为沿着这条测地线 $\|v_t\|_V^2 = \langle L v_t, v_t \rangle = \text{const.}$, 所以

$$\int_0^1 \langle L v_t, v_t \rangle_{L^2} dt = \langle L v_0, v_0 \rangle_{L^2} = \langle v_0, v_0 \rangle_V.$$

所以配准问题变成了一个具有约束条件的能量极小问题, 这时能量

$$E(v, I_0, J) = \frac{1}{2} \langle v_0, v_0 \rangle_V + \frac{1}{2\sigma^2} \|I_0 \circ \phi_1^{-1} - J\|_{L^2}^2, \quad (8)$$

其中微分同胚 ϕ_t 是用测地线的初始向量 v_0 生成的测地线 v_t 所形成的微分同胚族 ϕ_t 在 $t=1$ 处的取值. 所以 $E(v, I_0, J)$ 中的约束条件应为

$$\begin{cases} v + K \operatorname{ad}_v^* m = 0 & (\text{EPDiff 方程}) \\ \dot{I} + \nabla I \cdot v = 0 & (\text{图像迁移方程}) \\ m - L v = 0 & (\text{动量的定义}) \end{cases} \quad (9)$$

也可以采用 Bayesian 模型来观察我们的能量 $E(v, I_0, J)$. 设我们的噪声模型在图像上的每个 voxel 处是 i.i.d. 高斯噪声, 则似然率 (Likelihood) 可表为

$$p(J|v, I_0, \sigma) = \frac{1}{(2\pi)^{M/2} \sigma^M} \exp\left(-\frac{\|I_0 \circ \phi_1^{-1} - J\|^2}{2\sigma^2}\right),$$

这里 M 是 voxel 的总数, σ^2 是噪声方差.

v 的先验概率是多变量高斯型, 即

$$p(v) = \frac{1}{(2\pi)^{M/2} |L|^{1/2}} \exp\left(-\frac{\langle Lv, v \rangle}{2}\right),$$

这里 $|L|$ 是算子 L 的行列式. 于是

$$\log p(v|I_0, J, \sigma) \propto -\frac{1}{2}\langle Lv, v \rangle - M \log \sigma - \frac{1}{2\sigma^2} \|I_0 \circ \phi_1^{-1} - J\|^2$$

因为求最大似然率相当于求负对数似然率的极小问题, 所以图像配准问题就相当于求

$$E(v, I, \sigma) = \frac{1}{2}\langle Lv, v \rangle + M \log \sigma + \frac{1}{2\sigma^2} \|I_1 - J\|^2 \quad (10)$$

的极小值问题, 其中 I_1 是变形图像 I_t 在 $t=1$ 时的取值. 这里比前面的模型稍复杂一些, 即方差值 σ^2 也作为可调整的参数.

对这个能量极小问题可采用 Lagrange 乘子法, 将其转化为无约束的变分问题. 为此, 我们定义增强能量 (augmented energy):

$$\begin{aligned} \tilde{E}(v, I, \sigma, \hat{v}, \hat{I}, \hat{m}) = E(v, I, \sigma) &+ \int_0^1 [\langle \hat{v}, \dot{v} + K \operatorname{ad}_v^* m \rangle_{L^2} \\ &+ \langle \hat{I}, \dot{I} + \nabla I \cdot v \rangle_{L^2} \\ &+ \langle \hat{m}, m - Lv \rangle_{L^2}] dt \end{aligned} \quad (11)$$

这里 $\hat{v}_t, \hat{i}_t, \hat{m}_t$ 分别是相应于三个约束方程 (EPDiff 方程、图像迁移方程和动量定义) 的 Lagrange 乘子。

我们采用负梯度下降法去求解上述变分问题。

经计算, \tilde{E} 关于初始速度 v_0 的梯度为

$$\nabla_{v_0} \tilde{E} = v_0 - K \hat{v}_0. \quad (12)$$

(具体计算过程详见下面的 §3.)

所以初始速度 v_0 的迭代格式为

$$v_0^{(k+1)} = v_0^{(k)} - \tau (v_0^{(k)} - K \hat{v}_0^{(k)}), \quad (13)$$

这里 τ 是迭代步长。

将初始速度的迭代收敛值 v_0 作为 EPDiff 方程的初值可解出测地线 v_t , 再用

$$\begin{cases} \frac{d\phi_t(x)}{dt} = v_t(\phi_t(x)) \\ \phi_t|_{t=0} = id \end{cases}$$

可生成微分同胚族 ϕ_t , 则 $\phi_1(x)$ 为最终所需求出的大尺度变形的微分同胚。

这时, 不难看出

$$\sigma^2 = \frac{1}{M} \| I_0 \circ \phi_1^{-1} - J \|_{L^2}^2. \quad (14)$$

§3. \tilde{E} 关于 I, v, m 的一阶变分的推导过程.

3.1. 考虑 \tilde{E} 关于依赖于时间 t 的变量 I 的变分计算.

$$\begin{aligned}
 \partial_I \tilde{E} &= \frac{\partial}{\partial \varepsilon} \bigg|_{\varepsilon=0} \int_0^1 \langle \hat{I}, (\dot{I} + \varepsilon \delta \dot{I}) + \nabla(I + \varepsilon \delta I) \cdot v \rangle_{L^2} \\
 &\quad + \frac{1}{\sigma^2} \langle \delta I_1, I_1 - J \rangle_{L^2} \\
 &= \frac{1}{\sigma^2} \langle \delta I_1, I_1 - J \rangle_{L^2} + \int_0^1 \langle \hat{I}, \delta \dot{I} + \nabla \delta I \cdot v \rangle_{L^2} dt \\
 &= \frac{1}{\sigma^2} \langle \delta I_1, I_1 - J \rangle_{L^2} + \langle \hat{I}, \delta I \rangle_{L^2} \bigg|_{t=0}^{t=1} - \int_0^1 \langle \dot{\hat{I}}, \delta I \rangle_{L^2} dt \\
 &\quad + \int_0^1 \langle \hat{I}, \nabla \delta I \cdot v \rangle_{L^2} \\
 &= \frac{1}{\sigma^2} \langle \delta I_1, I_1 - J \rangle_{L^2} + \langle \hat{I}_1, \delta I_1 \rangle_{L^2} - \langle \hat{I}_0, \delta I_0 \rangle_{L^2} \\
 &\quad - \int_0^1 \langle \dot{\hat{I}} + \nabla \cdot (\hat{I} v), \delta I \rangle_{L^2} dt. \tag{15}
 \end{aligned}$$

3.2 考虑 \tilde{E} 关于 v 的变分计算.

$$\begin{aligned}
 \partial_v \tilde{E} &= \langle L v_0, v_0 \rangle_{L^2} + \frac{\partial}{\partial \varepsilon} \bigg|_{\varepsilon=0} \int_0^1 \langle \hat{v}, \varepsilon \delta \dot{v} + K \text{ad}_{v+\varepsilon \delta v}^* \hat{v}, m \rangle_{L^2} \\
 &\quad + \langle \hat{I}, \dot{I} + \nabla I \cdot (v + \varepsilon \delta v) \rangle_{L^2} \\
 &\quad + \langle \hat{m}, m - L(v + \varepsilon \delta v) \rangle_{L^2} \\
 &= \langle L v_0, \delta v_0 \rangle_{L^2} + \int_0^1 \langle v, \delta \dot{v} \rangle dt + \frac{\partial}{\partial \varepsilon} \bigg|_{\varepsilon=0} \int_0^1 \langle \text{ad}_{v+\varepsilon \delta v} K \hat{v}, m \rangle_{L^2} dt \\
 &\quad + \int_0^1 \langle \hat{I}, \nabla I \cdot \delta v \rangle_{L^2} dt - \int_0^1 \langle \hat{m}, m \delta v \rangle_{L^2} dt \\
 &= \langle L v_0, \delta v_0 \rangle_{L^2} + \langle \hat{v}, \delta v \rangle_{L^2} \bigg|_{t=0}^{t=1} - \int_0^1 \langle \dot{\hat{v}}, \delta v \rangle_{L^2} dt \\
 &\quad + \frac{\partial}{\partial \varepsilon} \bigg|_{\varepsilon=0} \int_0^1 \langle -\text{ad}_{K \hat{v}}(v + \varepsilon \delta v), m \rangle_{L^2} dt \\
 &\quad + \int_0^1 \langle \hat{I}, \nabla I \cdot \delta v \rangle_{L^2} dt - \int_0^1 \langle \hat{m}, m \delta v \rangle_{L^2} dt
 \end{aligned}$$

$$\begin{aligned}
&= \langle L v_0, \delta v_0 \rangle_{L^2} + \langle \hat{v}_1, \delta v_1 \rangle_{L^2} - \langle \hat{v}_0, \delta v_0 \rangle_{L^2} \\
&\quad + \int_0^1 \langle -\text{ad}_{K\hat{v}}^* m + \hat{I} \nabla I - \dot{\hat{v}} - L\hat{m}, \delta v \rangle_{L^2} dt
\end{aligned} \tag{16}$$

3.3.

$$\begin{aligned}
\partial_m \tilde{E} &= \frac{\partial}{\partial \varepsilon} \bigg|_{\varepsilon=0} \int_0^1 \left(\langle \hat{v}, K \text{ad}_v^* (m + \varepsilon \delta m) \rangle_{L^2} + \langle \hat{m}, (m + \varepsilon \delta m) \rangle_{L^2} \right) dt \\
&= \int_0^1 \langle \text{ad}_v K \hat{v} + \hat{m}, \delta m \rangle_{L^2} dt.
\end{aligned}$$

3.4. 因为在最优解处, 上述三变量均应为0, 即 $\partial_I \tilde{E} = 0$, $\partial_v \tilde{E} = 0$, $\partial_m \tilde{E} = 0$, 而且在最优解 (I, v) 处应有 $\begin{cases} \delta I_0 = 0 \\ \delta v_0 = 0 \end{cases}$, 于是我们可将 $\hat{v}, \hat{I}, \hat{m}$ 设定

为

$$\begin{cases} -\hat{I} - \nabla \cdot (\hat{I} v) = 0 \\ -\text{ad}_{K\hat{v}}^* m + \hat{I} \nabla I - \dot{\hat{v}} - L\hat{m} = 0 \\ \text{ad}_v K\hat{v} + \hat{m} = 0 \end{cases}, \tag{18}$$

而且令

$$\begin{cases} \hat{v}_1 = 0 \\ \hat{I}_1 = \frac{1}{\sigma^2} (I, -J) \end{cases}, \tag{19}$$

这样就确保了在最优解处, 增强能量 \tilde{E} 关于 I, v, m 的一阶变分为0. 我们将上述关于 \hat{I}, \hat{v} 和 \hat{m} 的末方程视为一组 ODE, 且带有初始条件 (19), 并称其为伴随方程 (adjoint equations). 这样, 在计及了伴随方程后, $\partial_v \tilde{E}$ 就

简化为

$$\begin{aligned}\partial_{v_0} \tilde{E} &= \langle L v_0, \delta v_0 \rangle_{L^2} - \langle \hat{v}_0, \delta v_0 \rangle_{L^2} = \langle L v_0 - \hat{v}_0, \delta v_0 \rangle_{L^2} \\ &= \langle K(L v_0 - \hat{v}_0), \delta v_0 \rangle_V = \langle v_0 - K \hat{v}_0, \delta v_0 \rangle_V,\end{aligned}$$

所以我们就得到了增强能量关于初始向量 v_0 的一阶变分为

$$\nabla_{v_0} \tilde{E} = v_0 - K \hat{v}_0.$$

因此,在用更梯度下降法计算迭代式(13)时,为了计算 $v_0^{(k)} - K \hat{v}_0^{(k)}$, 就必须先从初始向量 $v_0^{(k)}$ 出发,通过 EPDiff 方程解出 $v_t^{(k)}$, 再根据常微分方程组(1)让 t 从 0 到 1 解出微分同胚族 $\phi_t^{(k)}$, 于是 $v_t^{(k)}$, $m_t^{(k)}$, $\phi_t^{(k)}$, $I_t^{(k)}$ 均已算出。然后再根据伴随方程(18)及初始条件(19)让 t 从 1 反向解到 $t=0$, 最终解得 $\hat{v}_0^{(k)}$ 。

§4. 讨论 Atlas building 前的一些预备知识

4.1. Expectation Maximization Algorithm (EM 算法)

X 是随机变量, 它依赖于一个参数族。我们希望找到某个参数 θ , 使得

$$P(X|\theta)$$

达到最大。我们希望通过迭代 $\{\theta_n\}$ 得出最优解。设已算出 θ_n , 希望计算 θ_{n+1} 。

令

$$L(\theta) = \ln P(X|\theta).$$

所以等价也可讨论

$$L(\theta) - L(\theta_n) = \ln P(X|\theta) - \ln P(X|\theta_n)$$

以最大化解.

设问题存在隐生变量集合 Z , 所以

$$P(X|\theta) = \sum_{z \in Z} P(X|z, \theta) \cdot P(z|\theta).$$

利用 Jensen 不等式

$$\left(\text{对满足 } \sum_{i=1}^n \lambda_i = 1 \text{ 的系数 } \lambda_i \geq 0, \text{ 有 } \ln\left(\sum_{i=1}^n \lambda_i x_i\right) \geq \sum_{i=1}^n \lambda_i \ln(x_i). \right)$$

可推出

$$\begin{aligned} L(\theta) - L(\theta_n) &= \ln\left(\sum_z P(X|z, \theta) P(z|\theta)\right) - \ln P(X|\theta_n) \\ &= \ln\left[\sum_z P(z|X, \theta_n) \cdot \frac{P(X|z, \theta) P(z|\theta)}{P(z|X, \theta_n)}\right] - \ln P(X|\theta_n) \\ &\geq \sum_z P(z|X, \theta_n) \ln\left(\frac{P(X|z, \theta) P(z|\theta)}{P(z|X, \theta_n)}\right) - \ln P(X|\theta_n) \\ &= \sum_z P(z|X, \theta_n) \ln\left(\frac{P(X|z, \theta) P(z|\theta)}{P(z|X, \theta_n) P(X|\theta_n)}\right) \\ &\triangleq \Delta(\theta|\theta_n) \end{aligned}$$

令

$$\ell(\theta|\theta_n) = L(\theta_n) + \Delta(\theta|\theta_n),$$

所以

$$L(\theta) \geq \ell(\theta|\theta_n),$$

而且对 $\theta = \theta_n$ 处

$$\begin{aligned} \ell(\theta|\theta_n) &= L(\theta_n) + \Delta(\theta_n|\theta_n) = L(\theta_n) + \sum_z P(z|X, \theta_n) \ln \frac{P(X|z, \theta_n) P(z|\theta_n)}{P(z|X, \theta_n) P(X|\theta_n)} \\ &= L(\theta_n) + \sum_z P(z|X, \theta_n) \ln \frac{P(X, z|\theta_n)}{P(X, z|\theta_n)} = L(\theta_n). \end{aligned}$$

所以 EM 算法是去找 θ , 使得 $l(\theta | \theta_n)$ 达到最大:

$$\begin{aligned}
 \theta_{n+1} &= \arg\max_{\theta} \{ l(\theta | \theta_n) \} \\
 &= \arg\max_{\theta} \left\{ L(\theta_n) + \sum_z P(z | X, \theta_n) \ln \frac{P(X|z, \theta) P(z | \theta)}{P(X | \theta_n) P(z | X, \theta_n)} \right\} \\
 &= \arg\max_{\theta} \left\{ \sum_z P(z | X, \theta_n) \ln (P(X|z, \theta) P(z | \theta)) \right\} \\
 &= \arg\max_{\theta} \left\{ \sum_z P(z | X, \theta_n) \ln \left(\frac{P(X, z, \theta)}{P(z, \theta)} \cdot \frac{P(z, \theta)}{P(\theta)} \right) \right\} \\
 &= \arg\max_{\theta} \left\{ \sum_z P(z | X, \theta_n) \ln P(X, z | \theta) \right\} \\
 &= \arg\max_{\theta} \left\{ E_{Z|X, \theta_n} \{ \ln P(X, z | \theta) \} \right\}.
 \end{aligned}$$

因此 EM 算法分为两步:

1. E-Step: 确定出条件期望值 $Q(\theta) = E_{Z|X, \theta_n} \{ \ln P(X, z | \theta) \}$
2. M-Step: 关于 θ 求 $Q(\theta)$ 的最大值.

于是我们有必要研究下述问题:

设随机变量 Z 的条件概率分布密度函数 (pdf) 为 $p(Z | X, \theta_n)$, 我们需要根据这个 pdf 函数造出 Z 的 S 个样本 $\{z_1, \dots, z_S\}$, 于是

$$Q(\theta) \approx \frac{1}{S} \sum_{j=1}^S \ln P(X, z_j | \theta).$$

4.2 Hamiltonian Monte Carlo 取样方法 (HMC)

为了根据 pdf 函数 $f(x)$ 去取样, 我们定义一个 Hamiltonian:

$$H(x, \mu) = \underbrace{U(x)}_{\text{势能}} + \underbrace{V(\mu)}_{\text{动能}}, \quad \text{这里 } x \text{ 是位置, } \mu \text{ 是动量.}$$

可取 $U(x) = -\log f(x)$

$V(\mu) = -\log g(\mu)$, 这里 $g(\mu)$ 不妨取为各向同性的高斯分布密度.
(例如 $g(\mu) = e^{-\frac{\mu^2}{2}}$)

利用 Hamiltonian 系统去求解

$$\begin{cases} \dot{x} = \frac{\partial H}{\partial \mu} \\ \dot{\mu} = -\frac{\partial H}{\partial x} \end{cases} \quad (*)$$

从 (x, μ) 解出下一时刻的 $(\tilde{x}, \tilde{\mu})$, 再按

$$P(\text{接受}) = \min(1, \exp(-U(\tilde{x}) - V(\tilde{\mu}) + U(x) + V(\mu)))$$

的概率去决定是否接受 \tilde{x} 为一个新的样本.

我们采用青蛙跳 (leapfrog) 方法去求解 Hamiltonian 系统 (*).

我们把从时刻 τ 经步长 ε 到达时刻 $\tau + \varepsilon$ 的计算过程分成三步:

第一步 $\mu(\tau + \varepsilon/2) = \mu(\tau) + \frac{\varepsilon}{2} \frac{\partial \log f}{\partial x}(x(\tau))$

第二步 $x(\tau + \varepsilon) = x(\tau) + \varepsilon \mu(\tau + \varepsilon/2)$

第三步 $\mu(\tau + \varepsilon) = \mu(\tau + \varepsilon/2) + \frac{\varepsilon}{2} \frac{\partial \log f}{\partial x}(x(\tau + \varepsilon))$

§5. Atlas building in Diffeomorphic Image Registration

给定一组图像 J_1, \dots, J_N .

希望找出一个公共模板图像 I^* 及该组图像流形中 K 条测地线的切向量场 v_t^k , 使得

$$I^* = \operatorname{argmin}_I \frac{1}{N} \sum_{k=1}^N \left(\int_0^1 \langle L v_t^k, v_t^k \rangle dt + \frac{1}{2\sigma^2} \| I \circ (\phi_1^k)^{-1} - J_k \|^2 \right)$$

如前所述, 我们可以定义能量

$$E(v_0, I) = \sum_{k=1}^N \langle v_0^k, v_0^k \rangle_V + \frac{1}{2\sigma^2} \| I \circ (\phi_1^k)^{-1} - J_k \|_{L^2}^2$$

这里我们运用了测地射击 (geodesic shooting) 技术, 由初始向量场 v_0^k 所确定的测地线族为 ϕ_t^k , 并记变换图像为 $I_t^k(x) = I((\phi_t^k)^{-1}(x))$.

如果从 Bayesian 模型的角度来观察, 或然率 (Likelihood) 可表为

$$p(J_k | v_0^k, I, \sigma) = \frac{1}{(2\pi)^{M/2} \sigma^M} \exp \left(- \frac{\| I \circ (\phi_1^k)^{-1} - J_k \|^2}{2\sigma^2} \right)$$

而 v_0^k 的先验概率

$$p(v_0^k) = \frac{1}{(2\pi)^{M/2} \|L\|^{1/2}} \exp \left(- \frac{\langle L v_0^k, v_0^k \rangle_{L^2}}{2} \right)$$

所以

$$\begin{aligned} \log \prod_{k=1}^N p(J_k, v_0^k | I, \sigma) &\propto -\frac{1}{2} \sum_{k=1}^N \langle L v_0^k, v_0^k \rangle_{L^2} \\ &\quad - MN \log \sigma - \frac{1}{2\sigma^2} \sum_{k=1}^N \| I \circ (\phi_1^k)^{-1} - J_k \|^2 \\ &\stackrel{\text{def}}{=} E(v_0^k, I, \sigma) \end{aligned}$$

这里 σ^2 也成为该模型的可供调节的参数.

这时能量带有的约束条件为

$$\begin{cases} \dot{v}^k + k \operatorname{ad}_{v^k}^* m^k = 0 & (\text{EPDiff方程}) \\ \dot{I}^k + \nabla I^k \cdot v^k = 0 & (\text{图像迁移方程}) \\ m^k - L v^k = 0 & (\text{动量定义}) \end{cases}$$

这时增强能量为

$$\begin{aligned} \tilde{E}(v_o^k, I, \sigma, \hat{v}^k, \hat{I}^k, \hat{m}^k) &= E(v_o^k, I, \sigma) \\ &+ \int_0^1 \left[\langle \hat{v}^k, \dot{v}^k + k \operatorname{ad}_{v^k}^* m^k \rangle_{L^2} \right. \\ &\quad + \langle \hat{I}^k, \dot{I}^k + \nabla I^k \cdot v^k \rangle_{L^2} \\ &\quad \left. + \langle \hat{m}^k, m^k - L v^k \rangle_{L^2} \right] dt \end{aligned}$$

相应的伴随方程为

$$\begin{cases} \dot{\hat{I}}^k + \nabla \cdot (\hat{I}^k v^k) = 0 \\ -\operatorname{ad}_{k \hat{v}^k}^* + \hat{I}^k \nabla I^k - \dot{\hat{v}}^k - L \hat{m}^k = 0 \\ \operatorname{ad}_{v^k} k \hat{v}^k + \hat{m}^k = 0 \end{cases}$$

附带的初始条件

$$\begin{cases} \hat{v}_1^k = 0 \\ \hat{I}_1^k = \frac{1}{\sigma^2} (I_1^k - J_k) \end{cases}$$

我们利用EM算法去求解增强能量 \tilde{E} 的优化问题。这时参数集为 $\theta = (I, \sigma)$ ，隐生变量为 v_o^k ， $k=1, \dots, N$ 。

1. E-Step: 计算

$$\begin{aligned} Q(\theta | \theta^{(i)}) &= E_{v_o^k | J_k; \theta^{(i)}} [\tilde{E}(v_o^k, I, \sigma, \hat{v}^k, \hat{I}^k, \hat{m}^k)] \\ &\approx \frac{1}{S} \sum_{j=1}^S \sum_{k=1}^N \tilde{E}(v_o^{kj}, I, \sigma, \hat{v}^k, \hat{I}^k, \hat{m}^k), \end{aligned}$$

这里 v_o^{kj} , ($j=1, \dots, S$) 为 v_o^k 的取样, 这时 pdf 函数为 $p(v_o^k | J_k, \theta^{(i)})$

2. M-Step: 求解优化问题

$$\theta^{(t+1)} = \operatorname{argmin}_{\theta} Q(\theta | \theta^{(t)})$$

对 E-Step 而言, 剩下的问题是如何用 HMC 取样法求出 v_o^k 的 S 个样车

$$v_o^{kj}, \quad j=1, \dots, S.$$

关键是要写出这时的 Hamiltonian 系统. 令 Hamiltonian 为

$$H(v_o^k, \mu^k) = U(v_o^k) + V(\mu^k)$$

其中

$$\begin{cases} U(v_o^k) = -\log p(v_o^k | J^k; \theta) \\ V(\mu^k) = \langle L \mu^k, \mu^k \rangle \end{cases}$$

所以 Hamiltonian 系统为

$$\begin{cases} \frac{dv_o^k}{dt} = \frac{\partial H}{\partial \mu^k} = L \mu^k \\ \frac{d\mu^k}{dt} = -\frac{\partial H}{\partial v_o^k} = -\nabla_{v_o^k} \tilde{E} = -(v_o^k - K \hat{v}_o^k). \end{cases}$$

为了计算 \hat{v}_o^k , 我们必须运用 EPDiff 方程, 将初始向量 v_o^k 从 $t=0$ 解到 $t=1$, 然后再从 $t=1$ 出发反向求解伴随方程, 得到 $t=0$ 时的 \hat{v}_o^k .

对 M-Step 而言, 迭代过程是简单的, 我们有 closed form.

$$\sigma^2 = \frac{1}{MNS} \sum_{j=1}^S \sum_{k=1}^N \| I \circ (\phi_1^{kj})^{-1} - J^k \|^2$$

$$I = \frac{\sum_{j=1}^S \sum_{k=1}^N J^k \circ \phi_1^{kj} |D\phi_1^{kj}|}{\sum_{j=1}^S \sum_{k=1}^N |D\phi_1^{kj}|},$$

其中 ϕ^{kj} 是由 v_o^{kj} 所定义的微分同胚.

本文所述内容可通过下面两篇论文及其参考文献来获得:

[1] Zhang, M., Singh, N., Fletcher, P. T., 2013, Bayesian estimation of regularization and atlas building in diffeomorphic image registration, In: Information Processing in Medical Imaging, Springer, p.37-48.

[2] Miaomiao Zhang, P. Thomas Fletcher, Bayesian Principal geodesic analysis for estimating intrinsic diffeomorphic image variability, Medical Image Analysis 25 (2015) 37-44.