


定义在3D点云上的函数的TV项表达式

(A)



这里 \vec{e}_3 是曲面 S 上点 p 处的单位法向量,

\vec{e}_1, \vec{e}_2 是曲面 S 上点 p 处的两个单位正交的.

所以作为 p 的邻点 q_i , 它关于 p 处的坐标系 $\{\vec{e}_1, \vec{e}_2, \vec{e}_3\}$ 而言

即 q_i 关于这个坐标系的曲面坐标为 (u_i^1, u_i^2) , 它关于切平面的高度为 z_i .

所以我们可以由此确定出曲面 S 在 p 点处的局部形状为

$$z \approx \frac{1}{2} (k_1 (u^1)^2 + k_2 (u^2)^2),$$

这里 k_1, k_2 分别是曲面 S 在 p 点处的主曲率.

(参考: C. Shen, Y. Peng and G. Zhang, Denoising point clouds pulling-back method,

Proc. of SPIE,
Vol. 7798,
779807)


如果我们已经得到了在 p 处 $\{\vec{e}_1, \vec{e}_2, \vec{e}_3\}$ 及每个邻点的局部坐标

(根据邻点 q_i 的位置)

曲面 S 上的

(u_i^1, u_i^2) 及 $z_i(u_i^1, u_i^2)$, 那么我们可以用下列办法求出函数 f 在 p 点处的 Total Variation 的表达式,

p 的邻域关系: 以曲面坐标为 (u_1^i, u_2^i) , 所以从 $p=(0,0)$ 指向 (u_1^i, u_2^i) 的方向为 (u_1^i, u_2^i) , 相应的单位向量为 (v_1^i, v_2^i) , 则



$$v_i^\alpha = \frac{u_i^\alpha}{l_i}, \text{ 其中 } l_i = \sqrt{(u_1^i)^2 + (u_2^i)^2},$$

而且

$$(v_1^i, v_2^i) = (\cos \theta_i, \sin \theta_i),$$

$$(u_1^i, u_2^i) = l_i (v_1^i, v_2^i).$$

设 f 为定义在 3D 点云上的一个函数.

$$f(p) = f(0), \quad f(q_i) = f(u_1^i, u_2^i), \quad \text{且证 } f(p) = f(0),$$

则差商

$$M_i = \frac{f(u_1^i, u_2^i) - f(0)}{l_i} \approx \frac{\partial f}{\partial u_1} \cos \theta_i + \frac{\partial f}{\partial u_2} \sin \theta_i \\ = \frac{\partial f}{\partial u_1} v_1^i + \frac{\partial f}{\partial u_2} v_2^i = \frac{\partial f}{\partial u^\alpha} v_i^\alpha, \quad \alpha=1,2, \text{ 上下标为指标向量和.}$$

取在点云确定邻域内 $\nabla f = \left(\frac{\partial f}{\partial u_1}, \frac{\partial f}{\partial u_2} \right)_{p=0}$ 记为 $\begin{pmatrix} X_1 \\ X_2 \end{pmatrix}$, 使得

$$\sum_{i=1}^K (X_1 v_1^i + X_2 v_2^i - M_i)^2 = \min,$$

(这里 K 是 p 的邻域关系 q_i 的个数)

$$\text{即 } X^* = \arg \min_X \sum_{i=1}^K (X_\alpha v_i^\alpha - M_i)^2.$$

(C)

对 X_α 求变分得到

$$\sum_i (X_\beta v_i^\beta - M_i) v_i^\alpha = 0, \text{ 即 } \sum_i v_i^\alpha v_i^\beta X_\beta = \sum_i M_i v_i^\alpha$$

令 $\overset{2 \times 2 \text{ 阵}}{A} = (a^{\alpha\beta})$, 其中 $a^{\alpha\beta} = \sum_i v_i^\alpha v_i^\beta$

显然 A 是正定阵, 所以必有逆阵 $A^{-1} = (a^{-1})_{\alpha\beta}$

这是因为 \forall 向量 $P = (P_\alpha)$,

$$P^T A P = a^{\alpha\beta} P_\alpha P_\beta = \sum_i v_i^\alpha v_i^\beta P_\alpha P_\beta = \sum_i (v_i^\alpha P_\alpha)(v_i^\beta P_\beta) \geq 0.$$

$$\text{等号成立} \Leftrightarrow v_i^\alpha P_\alpha = 0, \forall i.$$

即 $v_i = (v_i^\alpha)$ 中至少有两个非零向量 v_i, v_j , 则由

$$P \perp P_i, P \perp P_j, \text{ 就可推出 } P \equiv 0.$$

令 $b^\alpha = \sum_i M_i v_i^\alpha$, 于是 $A X = b$, 即 $a^{\alpha\beta} X_\beta = b^\alpha$.

$$\therefore \begin{pmatrix} \frac{\partial f}{\partial u_1} \\ \frac{\partial f}{\partial u_2} \end{pmatrix} = X = A^{-1} b, \text{ 即 } \overset{\because X_\beta =}{(a^{-1})_{\beta\alpha}} b^\alpha = \sum_i (a^{-1})_{\beta\alpha} v_i^\alpha M_i$$

$$= \sum_i (a^{-1})_{\beta\alpha} v_i^\alpha \cdot \frac{f(p_i) - f(0)}{l_i}$$

因此函数 f 的梯度向量可看为其邻边处的函数值 $f(p_i)$ 以带权平均值,

$$X_\beta = \sum_i \underbrace{\frac{(a^{-1})_{\beta\alpha} v_i^\alpha}{l_i}}_{\text{关于 } p_i \text{ 的权}} f(p_i) - \underbrace{\frac{\sum_i (a^{-1})_{\beta\alpha} v_i^\alpha}{l_i}}_{\text{关于 } 0 \text{ 的权}} f(0)$$

关于 p_i 的权

关于 0 的权